

基于状态切换信号的动态因子配置研究

JUNXI

July 2026

目录

1 研究背景	2
2 系统总体架构	2
3 数据处理与因子构建	2
3.1 数据来源	2
3.2 数据读取模块	2
3.3 截面因子构建	3
4 SJM 状态识别模块	3
4.1 特征工程	4
4.2 SJM 模型训练	4
4.3 参数搜索	5
5 状态驱动动态因子配置	5
6 组合构建	6
7 Markowitz 组合优化	6
8 回测与评价	6
9 结果和总结	7

1 研究背景

传统多因子选股模型通常假设各风格因子的预测能力在整个市场周期内保持稳定。然而实际市场中，不同风格因子的表现具有明显的阶段性特征。例如，动量因子在趋势市场中通常具有较好的收益表现，而价值因子则更适用于均值回复市场。因此，固定因子权重难以适应不断变化的市场环境。

本项目以 Sparse Jump Model (SJM) 为核心，对各风格因子的市场状态进行识别，并根据因子在不同状态下的历史预测能力动态调整因子权重，从而构建一套状态驱动的动态多因子配置框架。

整体研究流程如下：

原始数据 → 因子构建 → 单因子收益 → SJM 状态识别 → 状态条件 ICIR → 动态因子配置 → 组合优化 → 回测评价

2 系统总体架构

整个项目主要由两个部分组成：

1. 单因子状态识别
2. 状态驱动多因子配置

第一部分利用 Sparse Jump Model 对每一个风格因子的 Bull/Bear 状态进行识别；第二部分根据识别得到的状态计算状态条件 ICIR，并动态调整因子权重，最终完成股票组合构建与回测。

3 数据处理与因子构建

3.1 数据来源

项目主要使用以下两类数据：

- A 股日线行情数据
- A 股财务报表数据

其中，行情数据用于计算收益率、波动率、换手率等市场指标；财务数据用于构建价值、质量及成长类因子。

3.2 数据读取模块

数据读取主要由 `factor/common.py` 完成，主要功能包括：

- 日线文件扫描
- 日期解析
- 股票价格面板构建
- 财务数据读取

3.3 截面因子构建

截面因子计算位于 `factor/cross_sectional.py`

项目共构建七类风格因子：

因子	计算方式
Momentum	12-1 动量收益率
Value	股东权益/总市值
Quality	ROE、现金流及负债率组合
Growth	收入增长率及利润增长率组合
Size	市值反向因子
Low Volatility	波动率反向因子
Liquidity	换手率滚动均值

所有因子统一调整方向，使得因子值越大表示未来收益预期越高：

$$FactorScore \uparrow \Rightarrow ExpectedReturn \uparrow$$

随后采用截面排序的方法构建单因子收益：

1. 每日按照因子值排序；
2. 做多前 20% 股票；
3. 做空后 20% 股票；
4. 得到因子多空收益序列。

该收益序列作为后续 SJM 状态识别模型的输入。

4 SJM 状态识别模块

项目采用 Sparse Jump Model (SJM) 识别因子的 Bull/Bear 状态。

核心实现位于 `sparse_jump_model.py`

主要包括：

- 状态中心估计 (State Centroid)
- 动态规划状态路径搜索 (Dynamic Programming)
- 稀疏特征权重更新
- 在线状态推断 (Online Prediction)

4.1 特征工程

特征构建位于 `feature/sjm_features.py`

主要构建以下特征：

- EWMA
- RSI
- Stochastic %K
- MACD Histogram
- Downside Volatility
- Rolling Beta
- 市场波动率
- 市场动量
- 上涨股票比例

所有特征均采用扩展窗口标准化：

$$z_t = \frac{x_t - \mu_{1:t}}{\sigma_{1:t}}$$

保证标准化过程不使用未来信息。

4.2 SJM 模型训练

模型训练位于 `sjm/train_sjm.py`

训练过程包括：

1. 构建训练特征矩阵；
2. 初始化状态中心；
3. 动态规划搜索最优状态路径；
4. 更新特征权重；
5. 重复迭代直至收敛。

优化目标为

$$\min_{\theta_0, \dots, \theta_{K-1}, s_0, \dots, s_{T-1}} \left\{ \sum_{t=0}^{T-1} \sum_{j=1}^p w_j (z_{t,j} - \theta_{s_t,j})^2 + \gamma \sum_{t=1}^{T-1} \mathbf{1}_{\{s_{t-1} \neq s_t\}} \right\}. \quad (1)$$

其中：

- $z_t = (x_t - \mu)/\sigma$ 表示训练集标准化后的特征向量；
- $z_{t,j}$ 表示第 t 个样本的第 j 个特征；
- $w_j \geq 0$ 表示第 j 个特征的稀疏权重；
- γ 为状态跳转惩罚系数（代码中对应 `jump_penalty`）；
- θ_k 表示第 k 个状态的质心（State Centroid）；
- $\theta_{s_t,j}$ 表示状态 s_t 下第 j 个特征对应的质心值；
- $s_t \in \{0, \dots, K-1\}$ 表示时刻 t 所对应的隐含状态；
- $\mathbf{1}_{\{\cdot\}}$ 为指示函数，当相邻两个时刻状态发生变化时取值为 1，否则取值为 0。

4.3 参数搜索

参数搜索位于 `sjm/tuner.py`

搜索参数包括：

- Jump Penalty (γ)
- Sparsity (κ) 用于控制稀疏程度
- 状态数量 (K)

模型最终采用验证集 Sharpe Ratio 作为评价指标选择最优参数。

5 状态驱动动态因子配置

多因子配置位于 `strategy/multifactor_backtest.py`

首先计算 Rank IC：

$$IC_t = Spearman(f_t, R_{t,t+H})$$

随后，仅保留与当前状态一致的历史 IC 样本，计算状态条件 ICIR：

$$ICIR = \frac{EWMA(IC)}{EWSTD(IC)}$$

指数衰减权重定义为：

$$w_i = 0.5^{a_i/120}$$

最终得到动态因子权重：

$$\omega_k = \frac{\max(ICIR_k, 0)}{\sum_j \max(ICIR_j, 0)}$$

6 组合构建

股票综合评分定义为：

$$\alpha_i = \sum_k \omega_k z(f_{i,k})$$

组合构建流程如下：

1. ST 股票过滤；
2. 换手率过滤；
3. Alpha 排序；
4. 选取 Top100 股票；
5. Ledoit-Wolf 协方差估计；
6. Markowitz 组合优化。

7 Markowitz 组合优化

采用均值-方差模型：

$$\max_w (\alpha^T w - \lambda w^T \Sigma w)$$

约束条件：

$$\sum_i w_i = 1$$

$$0 \leq w_i \leq 5\%$$

优化器采用 `scipy.optimize.minimize()` 中的 SLSQP 算法完成。

8 回测与评价

项目采用月频调仓：

1. 读取上一交易日状态；
2. 计算状态条件 ICIR；
3. 更新因子权重；
4. 构建 Alpha；
5. 优化组合；

6. 月初调仓。

评价指标由 `evaluation/metrics.py` 计算，包括：

- Annual Return
- Annual Volatility
- Sharpe Ratio
- Information Ratio
- Maximum Drawdown

此外，还统计 Bull/Bear 状态占比、平均持续时间以及状态切换次数。

9 结果和总结

本项目实现了一套完整的状态驱动动态因子配置框架。整个系统从数据读取、因子构建、SJM 状态识别、状态条件 ICIR 计算、动态因子配置到 Markowitz 组合优化形成了完整闭环。同时，通过扩展窗口标准化、在线状态推断、信号滞后及财务数据延迟等设计，有效避免了未来数据泄漏，为后续开展在线学习、动态风险预算及 Black-Litterman 资产配置等研究提供了可扩展的平台。

在风险偏好参数 $\lambda = 0.6$ 的设定下，策略的回测绩效指标如表 1 所示。

表 1: 策略回测绩效指标 ($\lambda = 0.6$)

评价指标	参数值 / 表现
风险偏好参数 (λ)	0.600
累计收益率 (Total Return)	14.63%
年化收益率 (Annual Return)	2.62%
夏普比率 (Sharpe Ratio)	0.106
最大回撤 (Maximum Drawdown)	-36.17%
年化换手率 (Turnover)	55.30%

回测期间不同子状态策略的净值走势如图 1 所示：




图 1: 不同子状态策略净值走势 ($\lambda = 0.6$)