

基于状态切换信号的动态因子配置研究

LIN JUNXI

July 2026

目录

1 研究背景	3
2 系统总体架构	3
3 数据处理与因子构建	3
3.1 数据来源	3
3.2 数据读取模块	3
3.3 截面因子构建	4
4 SJM 状态识别模块	4
4.1 特征工程	5
4.2 SJM 模型训练	5
4.3 参数搜索	6
5 状态驱动动态因子配置	6
6 组合构建	7
7 Markowitz 组合优化	7
8 回测与评价	7
9 结果和总结	8
10 进一步改进	9
10.1 状态稳定性得分 (State Stability Score, SSS)	12
10.1.1 (1) 状态切换频率 (Switch Frequency)	13
10.1.2 (2) 平均状态持续时间 (Average State Duration)	13
10.1.3 (3) 持续时间离散程度 (Duration Variance)	14
10.1.4 (4) 最长状态占比 (Longest Regime Ratio)	14
10.1.5 (5) 指标标准化	15
10.1.6 (6) 状态稳定性得分 (State Stability Score)	15

10.2 因子状态稳定性评价结果	15
10.2.1 不同稳定性因子组合的样本外回测结果	16
11 研究不足与未来展望	19
11.1 夏普比率较低的原因	19
11.2 方法在 A 股市场中的局限性	20

1 研究背景

传统多因子选股模型通常假设各风格因子的预测能力在整个市场周期内保持稳定。然而实际市场中，不同风格因子的表现具有明显的阶段性特征。例如，动量因子在趋势市场中通常具有较好的收益表现，而价值因子则更适用于均值回复市场。因此，固定因子权重难以适应不断变化的市场环境。

本项目以 Sparse Jump Model (SJM) 为核心，对各风格因子的市场状态进行识别，并根据因子在不同状态下的历史预测能力动态调整因子权重，从而构建一套状态驱动的动态多因子配置框架。

整体研究流程如下：

原始数据 → 因子构建 → 单因子收益 → SJM 状态识别 → 状态条件 ICIR → 动态因子配置 → 组合优化 → 回测评价

2 系统总体架构

整个项目主要由两个部分组成：

1. 单因子状态识别
2. 状态驱动多因子配置

第一部分利用 Sparse Jump Model 对每一个风格因子的 Bull/Bear 状态进行识别；第二部分根据识别得到的状态计算状态条件 ICIR，并动态调整因子权重，最终完成股票组合构建与回测。

3 数据处理与因子构建

3.1 数据来源

项目主要使用以下两类数据：

- A 股日线行情数据
- A 股财务报表数据

其中，行情数据用于计算收益率、波动率、换手率等市场指标；财务数据用于构建价值、质量及成长类因子。

3.2 数据读取模块

数据读取主要由 `factor/common.py` 完成，主要功能包括：

- 日线文件扫描
- 日期解析
- 股票价格面板构建
- 财务数据读取

3.3 截面因子构建

截面因子计算位于 `factor/cross_sectional.py`

项目共构建七类风格因子：

因子	计算方式
Momentum	12-1 动量收益率
Value	股东权益/总市值
Quality	ROE、现金流及负债率组合
Growth	收入增长率及利润增长率组合
Size	市值反向因子
Low Volatility	波动率反向因子
Liquidity	换手率滚动均值

所有因子统一调整方向，使得因子值越大表示未来收益预期越高：

$$FactorScore \uparrow \Rightarrow ExpectedReturn \uparrow$$

随后采用截面排序的方法构建单因子收益：

1. 每日按照因子值排序；
2. 做多前 20% 股票；
3. 做空后 20% 股票；
4. 得到因子多空收益序列。

该收益序列作为后续 SJM 状态识别模型的输入。

4 SJM 状态识别模块

项目采用 Sparse Jump Model (SJM) 识别因子的 Bull/Bear 状态。

核心实现位于 `sparse_jump_model.py`

主要包括：

- 状态中心估计 (State Centroid)
- 动态规划状态路径搜索 (Dynamic Programming)
- 稀疏特征权重更新
- 在线状态推断 (Online Prediction)

4.1 特征工程

特征构建位于 `feature/sjm_features.py`

主要构建以下特征：

- EWMA
- RSI
- Stochastic %K
- MACD Histogram
- Downside Volatility
- Rolling Beta
- 市场波动率
- 市场动量
- 上涨股票比例

所有特征均采用扩展窗口标准化：

$$z_t = \frac{x_t - \mu_{1:t}}{\sigma_{1:t}}$$

保证标准化过程不使用未来信息。

4.2 SJM 模型训练

模型训练位于 `sjm/train_sjm.py`

训练过程包括：

1. 构建训练特征矩阵；
2. 初始化状态中心；
3. 动态规划搜索最优状态路径；
4. 更新特征权重；
5. 重复迭代直至收敛。

优化目标为

$$\min_{\theta_0, \dots, \theta_{K-1}, s_0, \dots, s_{T-1}} \left\{ \sum_{t=0}^{T-1} \sum_{j=1}^p w_j (z_{t,j} - \theta_{s_t,j})^2 + \gamma \sum_{t=1}^{T-1} \mathbf{1}_{\{s_{t-1} \neq s_t\}} \right\}. \quad (1)$$

其中：

- $z_t = (x_t - \mu)/\sigma$ 表示训练集标准化后的特征向量；
- $z_{t,j}$ 表示第 t 个样本的第 j 个特征；
- $w_j \geq 0$ 表示第 j 个特征的稀疏权重；
- γ 为状态跳转惩罚系数（代码中对应 `jump_penalty`）；
- θ_k 表示第 k 个状态的质心（State Centroid）；
- $\theta_{s_t,j}$ 表示状态 s_t 下第 j 个特征对应的质心值；
- $s_t \in \{0, \dots, K-1\}$ 表示时刻 t 所对应的隐含状态；
- $\mathbf{1}_{\{\cdot\}}$ 为指示函数，当相邻两个时刻状态发生变化时取值为 1，否则取值为 0。

4.3 参数搜索

参数搜索位于 `sjm/tuner.py`

搜索参数包括：

- Jump Penalty (γ)
- Sparsity (κ) 用于控制稀疏程度
- 状态数量 (K)

模型最终采用验证集 Sharpe Ratio 作为评价指标选择最优参数。

5 状态驱动动态因子配置

多因子配置位于 `strategy/multifactor_backtest.py`

首先计算 Rank IC：

$$IC_t = Spearman(f_t, R_{t,t+H})$$

随后，仅保留与当前状态一致的历史 IC 样本，计算状态条件 ICIR：

$$ICIR = \frac{EWMA(IC)}{EWSTD(IC)}$$

指数衰减权重定义为：

$$w_i = 0.5^{a_i/120}$$

最终得到动态因子权重：

$$\omega_k = \frac{\max(ICIR_k, 0)}{\sum_j \max(ICIR_j, 0)}$$

6 组合构建

股票综合评分定义为：

$$\alpha_i = \sum_k \omega_k z(f_{i,k})$$

组合构建流程如下：

1. ST 股票过滤；
2. 换手率过滤；
3. Alpha 排序；
4. 选取 Top100 股票；
5. Ledoit-Wolf 协方差估计；
6. Markowitz 组合优化。

7 Markowitz 组合优化

采用均值-方差模型：

$$\max_w (\alpha^T w - \lambda w^T \Sigma w)$$

约束条件：

$$\sum_i w_i = 1$$

$$0 \leq w_i \leq 5\%$$

优化器采用 `scipy.optimize.minimize()` 中的 SLSQP 算法完成。

8 回测与评价

项目采用月频调仓：

1. 读取上一交易日状态；
2. 计算状态条件 ICIR；
3. 更新因子权重；
4. 构建 Alpha；
5. 优化组合；

6. 月初调仓。

评价指标由 `evaluation/metrics.py` 计算，包括：

- Annual Return
- Annual Volatility
- Sharpe Ratio
- Information Ratio
- Maximum Drawdown

此外，还统计 Bull/Bear 状态占比、平均持续时间以及状态切换次数。

9 结果和总结

本项目实现了一套完整的状态驱动动态因子配置框架。整个系统从数据读取、因子构建、SJM 状态识别、状态条件 ICIR 计算、动态因子配置到 Markowitz 组合优化形成了完整闭环。同时，通过扩展窗口标准化、在线状态推断、信号滞后及财务数据延迟等设计，有效避免了未来数据泄漏，为后续开展在线学习、动态风险预算及 Black-Litterman 资产配置等研究提供了可扩展的平台。

在风险偏好参数 $\lambda = 0.6$ 的设定下，策略的回测绩效指标如表 1 所示。

表 1: 策略回测绩效指标 ($\lambda = 0.6$)

评价指标	参数值 / 表现
风险偏好参数 (λ)	0.600
累计收益率 (Total Return)	14.63%
年化收益率 (Annual Return)	2.62%
夏普比率 (Sharpe Ratio)	0.106
最大回撤 (Maximum Drawdown)	-36.17%
年化换手率 (Turnover)	55.30%

回测期间不同子状态策略的净值走势如图 1 所示：




图 1: 不同子状态策略净值走势 ($\lambda = 0.6$)

10 进一步改进

我们发现模型对不同的因子状态识别能力有所不同，各个因子状态识别图如下




图 2: value 因子全期状态划分




图 3: size 因子全期状态划分




图 4: liquidity 因子全期状态划分




图 5: momentum 因子全期状态划分




图 6: lowvol 因子全期状态划分




图 7: quality 因子全期状态划分




图 8: growth 因子全期状态划分

我们发现不同的因子稳定状态不同，因子我们设计了一个指标 State Stability Score(SSS) 定义因子的稳定状态。该指标综合考虑状态切换频率、状态平均持续时间、持续时间离散程度以及最长状态占比四个维度，对状态识别结果进行统一评价。

10.1 状态稳定性得分 (State Stability Score, SSS)

设因子状态序列表示为

$$S = \{s_1, s_2, \dots, s_T\},$$

其中

$$s_t \in \{0, 1\},$$

分别表示第 t 个交易日处于 Bear 状态或 Bull 状态, T 为样本总交易日数。

10.1.1 (1) 状态切换频率 (Switch Frequency)

设

$$I_t = \begin{cases} 1, & s_t \neq s_{t-1}, \\ 0, & s_t = s_{t-1}, \end{cases} \quad t = 2, \dots, T.$$

则状态切换次数定义为

$$N_{\text{switch}} = \sum_{t=2}^T I_t.$$

进一步定义状态切换频率为

$$SF = \frac{N_{\text{switch}}}{T-1}.$$

其中

- N_{switch} 表示整个样本期间状态发生变化的次数;
- T 表示样本总交易日数;
- SF 越小, 说明状态切换越少, 状态越稳定。

10.1.2 (2) 平均状态持续时间 (Average State Duration)

设状态序列共划分得到 m 个连续状态区间, 每个区间持续时间分别为

$$D_1, D_2, \dots, D_m.$$

例如状态序列

$$BBBBBBRRRRBBBBRR$$

对应持续时间为

$$D = \{6, 4, 4, 2\}.$$

则平均状态持续时间定义为

$$ASD = \frac{1}{m} \sum_{i=1}^m D_i.$$

其中

- m 为连续状态区间个数；
- D_i 为第 i 个状态区间持续的交易日数；
- ASD 越大，说明状态持续时间越长，状态更加稳定。

10.1.3 (3) 持续时间离散程度 (Duration Variance)

为了刻画不同状态持续时间是否均衡，引入持续时间方差。
定义

$$DV = \frac{1}{m} \sum_{i=1}^m (D_i - ASD)^2.$$

其中

- DV 表示各状态持续时间的离散程度；
- DV 越小，说明各状态持续时间更加均衡；
- 若 DV 较大，则说明状态持续时间波动较大，稳定性较差。

10.1.4 (4) 最长状态占比 (Longest Regime Ratio)

设

$$D_{\max} = \max\{D_1, D_2, \dots, D_m\},$$

则最长状态占比定义为

$$LRR = \frac{D_{\max}}{T}.$$

其中

- $D_{\max}$ 表示最长连续状态持续时间；
- T 表示样本总交易日数；
- LRR 越大，说明存在持续时间较长的主导状态，状态识别更加稳定。

10.1.5 (5) 指标标准化

由于四项指标量纲不同，为保证其可比性，本文采用 Z-score 方法进行标准化。
对于任意指标 X ，

$$z(X) = \frac{X - \mu_X}{\sigma_X},$$

其中

- μ_X 为所有候选因子对应指标的均值；
- σ_X 为所有候选因子对应指标的标准差。

10.1.6 (6) 状态稳定性得分 (State Stability Score)

最终，定义状态稳定性得分为

$$SSS = -z(SF) + z(ASD) - z(DV) + z(LRR) \quad (2)$$

其中

- $-z(SF)$ ：状态切换越少越稳定；
- $z(ASD)$ ：状态持续时间越长越稳定；
- $-z(DV)$ ：状态持续时间越均衡越稳定；
- $z(LRR)$ ：最长状态占比越高越稳定。

因此，

$$SSS \uparrow$$

表示状态识别稳定性越高；

$$SSS \downarrow$$

表示状态频繁切换、持续时间较短且波动较大，状态稳定性较差。

10.2 因子状态稳定性评价结果

依据式 (2) 计算各因子的状态稳定性得分 (State Stability Score, SSS)，并按照得分由高到低进行排序，结果如表 2 所示。

表 2: 各因子状态稳定性得分 (SSS) 排序

排名	因子	SSS
1	Size	0.858344
2	Value	0.463001
3	Liquidity	0.102837
4	Growth	-0.031398
5	Momentum	-0.154571
6	Quality	-0.520113
7	Low Volatility	-0.718099

由表 2 可以看出, 不同因子的状态稳定性存在明显差异。我们发现 value, size, liquidity 因子状态识别十分稳定, momentum, growth 因子状态较为稳定, 而 quality, lowvol 因子状态切换较为频繁。因此我们将做几组对比实验, 选取状态稳定的因子进行配置

10.2.1 不同稳定性因子组合的样本外回测结果

value, size, liquidity 三因子配置结果如表 3所示:

表 3: value-size-liquidity 三因子回测

评价指标	参数值 / 表现
风险偏好参数 (λ)	0.700
累计收益率 (Total Return)	50.38%
年化收益率 (Annual Return)	8.04%
夏普比率 (Sharpe Ratio)	0.299
最大回撤 (Maximum Drawdown)	-37.37%
年化换手率 (Turnover)	54.76%

回测期间子状态策略的净值走势如图 9 所示:




图 9: value-size-liquidity 三因子回测

value, size, liquidity, growth 四因子配置结果如表 4所示：

表 4: value-size-liquidity-growth 四因子回测

评价指标	参数值 / 表现
风险偏好参数 (λ)	0.800
累计收益率 (Total Return)	48.89%
年化收益率 (Annual Return)	7.83%
夏普比率 (Sharpe Ratio)	0.292
最大回撤 (Maximum Drawdown)	-37.96%
年化换手率 (Turnover)	54.77%

回测期间子状态策略的净值走势如图 10 所示：




图 10: value-size-liquidity-growth 四因子回测

value, size, liquidity, momentum 四因子配置结果如表 5所示:

表 5: value-size-liquidity-momentum 四因子回测

评价指标	参数值 / 表现
风险偏好参数 (λ)	0.700
累计收益率 (Total Return)	60.35%
年化收益率 (Annual Return)	9.36%
夏普比率 (Sharpe Ratio)	0.338
最大回撤 (Maximum Drawdown)	-38.34%
年化换手率 (Turnover)	55.85%

回测期间子状态策略的净值走势如图 11 所示:




图 11: value-size-liquidity-momentum 四因子回测

我们发现经过因子筛选之后，累积收益率，年化收益率，夏普比率较原来均有大幅提升，其中 value-size-liquidity-momentum 表现最好。但是所有组合的夏普比率都不超过 0.5，处于较低水平。

11 研究不足与未来展望

本文基于 Sparse Jump Model (SJM) 构建了因子市场状态识别模型，并结合状态稳定性评价指标 (State Stability Score, SSS) 对因子进行筛选，实现了动态因子配置策略。实验结果表明，该方法能够在一定程度上提升组合收益，但样本外回测结果显示组合夏普比率仍然较低，说明模型仍存在一定局限性。具体分析如下。

11.1 夏普比率较低的原因

(1) A 股市场风格轮动速度较快。

SJM 建立在市场状态具有一定持续性的假设之上，而 A 股市场受政策变化、市场情绪及资金流向影响较大，不同风格之间轮动速度较快，导致因子状态持续时间较短，模型识别结果容易出现滞后，从而降低动态配置策略的有效性。

(2) 传统因子超额收益有所衰减。

近年来，价值 (Value)、成长 (Growth)、质量 (Quality) 等经典因子的超额收益逐渐减弱，即使市场状态识别较为准确，由于底层因子自身 Alpha 有限，组合整体收益提升仍然受到限制。

(3) 模型仅识别状态而无法预测收益强弱。

SJM 输出的是因子当前所处的 Bull 或 Bear 状态，并不能进一步刻画不同 Bull 状态之间收益水平的差异。因此模型能够判断市场状态，却无法区分不同状态下收益的强弱，从而限制了组合收益率的进一步提升。

(4) 因子之间存在较强相关性。

Value、Size 与 Liquidity 等因子之间具有一定相关性，在市场状态变化过程中往往表现出较高的一致性。因此，即使配置多个因子，组合实际承担的风险暴露仍然较为集中，难以充分发挥多因子分散风险的优势。

(5) 状态识别存在天然滞后性。

SJM 属于基于历史信息进行状态识别的方法，需要利用已有观测数据判断当前市场状态，因此状态转换通常只能在发生之后被识别，无法提前预测市场拐点，导致资产配置存在一定滞后。

(6) A 股市场噪声较大。

相比成熟市场，A 股市场更容易受到政策调控、市场情绪、游资交易及突发事件等因素影响，市场短期波动较大，导致因子状态出现频繁切换，降低了状态识别模型的稳定性。

(7) 动态权重估计存在误差。

本文采用历史滚动 IC 估计因子权重，而 IC 本身具有较大的时间波动性，当历史样本较短或市场环境发生变化时，权重估计容易产生较大误差，从而增加组合收益的不确定性。

(8) 未充分考虑实际交易成本。

本文回测仅考虑了组合调仓过程，尚未充分纳入冲击成本、滑点、交易佣金以及印花税等实际交易成本因素。在真实交易环境下，组合收益率及夏普比率可能进一步下降。

(9) 样本外市场环境发生变化。

模型训练阶段学习到的是历史市场状态，而近年来 A 股市场在注册制改革、ETF 快速发展、量化交易规模提升以及北向资金结构变化等因素影响下，市场微观结构发生了较大变化，历史状态规律可能无法完全适用于新的市场环境。

11.2 方法在 A 股市场中的局限性

虽然 SJM 能够较好地识别市场状态，但其在 A 股市场仍存在一定适用边界。

首先，A 股市场具有较强的政策驱动和情绪驱动特征，市场风格切换速度较快，状态持续性相较于成熟市场更弱，降低了状态识别模型的预测能力。

其次，传统因子近年来存在不同程度的因子拥挤（Factor Crowding）现象，部分经典因子的风险溢价逐渐下降，使得动态配置策略能够获取的超额收益有限。

此外，本文状态识别主要依赖历史收益及技术特征，尚未引入宏观经济变量、资金流向、分析师预期、事件驱动以及另类数据等信息，因此模型的信息利用仍然较为有限。

最后，SJM 本质属于历史状态识别模型，并不能预测未来市场状态的转换，对于突发事件、政策变化以及黑天鹅事件等导致的市场快速切换缺乏提前响应能力，因此模型在极端市场环境下容易失效。